

國立雲林科技大學資訊工程系

大學部實務專題

Department of Computer Science & Information Engineering

National Yunlin University of Science & Technology

Senior Design

AI 語音助理

AI voice assistant

蘇新宇、陳茂文、郭偉宏、簡士恩

Hsin-Yu Su、Mao-Wen Chen、Wei-Hung Kuo、Shih-En Chien

指導教授：鄭敦維 博士

Advisor: Dun-Wei Cheng, Ph.D.

中華民國 115 年 6 月

June 2026

2.5cm

(民國)

1 cm

115

2.5cm

大學部
實務專題

AI 語音助理

中文
論文
題目

資訊工程系

國立雲林科技大學

院校 所名	校址	招生 人数	备注
清华大学	北京	1000	
北京大学	北京	1000	
复旦大学	上海	1000	
上海交通大学	上海	1000	
浙江大学	杭州	1000	
南京大学	南京	1000	
武汉大学	武汉	1000	
中山大学	广州	1000	
南开大学	天津	1000	
厦门大学	厦门	1000	
山东大学	济南	1000	
吉林大学	长春	1000	
黑龙江大学	哈尔滨	1000	
新疆大学	乌鲁木齐	1000	
西藏大学	拉萨	1000	
内蒙古大学	呼和浩特	1000	
宁夏大学	银川	1000	
青海大学	西宁	1000	
甘肃大学	兰州	1000	
陕西大学	西安	1000	
山西大学	太原	1000	
河北大学	保定	1000	
河南大学	开封	1000	
湖北大学	武汉	1000	
湖南大学	长沙	1000	
四川大学	成都	1000	
重庆大学	重庆	1000	
贵州大学	贵阳	1000	
云南大学	昆明	1000	
广西大学	南宁	1000	
海南大学	海口	1000	
福建大学	福州	1000	
浙江大学	杭州	1000	
安徽大学	合肥	1000	
江西大学	南昌	1000	
广东大学	广州	1000	
香港大学	香港	1000	
澳门大学	澳门	1000	
台湾大学	台北	1000	

6.5cm

1 cm

著者
姓名

2cm

簡士恩 郭偉宏 陳茂文 蘇新宇

3cm

國立雲林科技大學
資訊工程系
實務專題合格認可證明

專題學生：蘇新宇、陳茂文、郭偉宏、簡士恩

實務專題題目：AI 語音助理

AI Voice Assistant

經評量合格，特此證明

指導教授簽名：郭偉宏

摘要

隨著語音助理在生活應用的普及，現行語音助理雖支援基本語意理解與指令操作，但多數缺乏對語意情緒的感知能力與角色互動的親和設計，難以提供真實對話般的陪伴感受。為補足此類互動限制，我們設計本系統欲作為解決方案。

本專題設計一套結合生成式人工智慧與虛擬角色互動技術的桌面語音系統「AI 語音助理」，旨在提供更自然且具情感連結的數位互動體驗。系統支援語音指令控制與對話互動，能執行應用程式開啟、網站瀏覽等操作，提供實用的日常桌面輔助功能。

本專題能在電腦桌面環境中運行，並以 LIVE2D 技術呈現虛擬角色形象。角色可根據使用者語音內容進行語音辨識 (Speech-to-Text)，並將語句傳送至語言模型生成回應。為提升回應速度與一致性，我們採用 OpenAI API 作為語言模型，並以串流方式回傳生成內容，透過語音合成模組 (Text-to-Speech) 轉為語音輸出，並結合情緒分析同步呈現對應表情，強化互動真實感與人性化體驗。

整體系統以串流架構為基礎，並透過 Unity 整合角色驅動、語音互動與任務執行流程，具備穩定回應與模組化擴充的潛力。未來，我們將持續優化互動品質，並朝向智慧健康照護應用發展。預期結合 IoT 生理量測設備與雲端照護平台，發展為能長時間陪伴、主動提醒與即時回應的健康小助手，提供長者或需要關懷的族群一個更溫暖且可靠的智慧夥伴。期望此系統能為智慧生活與長期照護場域帶來實質貢獻。

關鍵字：AI 語音助理、生成式人工智慧、語音辨識、語音合成、情緒分析、
虛擬角色互動

致謝

本專題能夠順利完成，最感謝的是鄭教授在整個研究過程中的悉心指導與無私支持。鄭教授不僅耐心傾聽我們的想法，適時提供研究方向上的建議，也從多元角度啟發我們思考，幫助我們釐清問題、掌握核心概念，讓我們在專題研究的每個階段都能有所成長。

在鄭教授的帶領下，我們逐步建立起獨立進行學術研究的能力，從過去被動學習轉為主動探索，透過閱讀文獻、實作應用，將知識實際轉化為成果。這樣的訓練不僅強化了我們的研究思維，更為未來不論是升學或投入職場打下了堅實基礎。

此外，教授也在我們準備碩士甄試期間，給予了許多寶貴的建議與實質的協助，無論是備審資料的撰寫、面試的準備，甚至是對於未來發展方向的指引，都給予我們極大的信心與支持。每次的會議與對談，對我而言都像是一場啟發，不僅解答了當下的困惑，更讓我對未來的學習與人生規劃有了更清晰的方向。

目錄

中文摘要	-----	i
致謝	-----	ii
目錄	-----	iii
圖目錄	-----	v
一、	緒論-----	1
1.1	研究動機-----	1
1.2	研究目的-----	1
1.3	技術發展與趨勢-----	1
二、	文獻探討-----	3
2.1	語音轉文字技術-----	3
2.2	語音合成技術-----	4
2.3	大型語言模型-----	4
2.4	情緒分析與互動式表情生成-----	5
2.4.1	使用者情緒分析-----	5
2.4.2	模型情緒表情生成-----	7
2.5	虛擬角色動態呈現與 Unity / Live2D 整合應用-----	7
2.6	外部應用程式與網頁控制技術-----	8
2.7	語音情緒辨識-----	9
三、	研究內容與方法-----	10
3.1	系統整體架構設計-----	10
3.2	語音分析-----	11
3.2.1	語音轉文字-----	11
3.2.2	語音情緒辨識-----	13
3.3	回應生成與對話歷史管理-----	14
3.4	語音合成-----	16
3.5	情緒分析與表情對應-----	17
3.6	虛擬角色呈現與 Unity / Live2D 整合-----	18
3.7	外部應用程式與網頁呼叫-----	20
3.8	串流架構整合與模組溝通流程-----	21
四、	實驗討論-----	24
4.1	實驗環境與開發平台-----	24
4.2	系統功能-----	24
4.2.1	語音辨識與語意理解-----	25
4.2.1.1	語音內容辨識-----	25
4.2.1.2	語音情緒分析模組選擇-----	25
4.2.1.3	情緒分析正確率測試-----	26
4.2.2	回應生成與語音合成-----	27
4.2.3	指令控制與 Function Calling 機制-----	28
4.2.4	情緒判斷與控制功能-----	29

4.2.4.1	情感分析的連貫性-----	30
4.2.4.2	情緒平滑化與時間序列控制-----	30
4.2.4.3	情感分析模組的選用與評估-----	31
4.2.4.4	情感分析與使用者-----	31
4.2.5	模型選擇-----	32
五、	結論-----	33
5.1	結論-----	33
5.2	未來展望-----	33
參考文獻	-----	34

圖目錄

圖一	有關情緒分析功能的多種應用與市場估值-----	2
圖二	系統整體架構流程圖-----	11
圖三	使用 Azure 呼叫雲端文字轉語音功能之參考架構-----	12
圖四	語音情緒辨識模組的簡易流程圖-----	13
圖五	LLM 回應產生流程架構圖-----	15
圖六	LLM 處理 Token 限制問題流程圖-----	15
圖七	情緒與語音合成模組架構圖-----	18
圖八	OpenAI 語言模型對工具函式呼叫的處理步驟-----	20
圖九	串流架構與模組溝通簡易流程圖-----	23
圖十	語音情緒分類模型的正確率測試，並以混淆矩陣表示結果---	27
圖十一	Function Calling 請求 JSON 之範例格式-----	29

一、緒論

1.1 研究動機

隨著語音助理技術在日常生活中的普及，市面上已有多款語音助理應用，能夠執行如查詢天氣、開啟應用程式、控制家電等任務。然而，目前主流語音助理多半侷限於語意理解與簡單指令執行，缺乏對語氣情緒的辨識與反應能力，也未能提供視覺互動上的陪伴感。因此，在實際使用情境中常給人冰冷、生硬、無情感的印象，難以提供真正富有情感交流的互動體驗。

為提升語音互動的沉浸感與親和力，本專題以「AI 語音助理」為核心，結合虛擬角色呈現技術 Live2D，打造具備語音辨識、語意生成、情緒分析與表情同步能力的語音互動系統。希望藉由此系統的實作，使使用者在語音溝通中不僅獲得資訊上的便利，更能感受到「會聽、會說、有情緒」的虛擬互動夥伴，融入生活陪伴之中。進一步也將探索該系統在智慧桌面應用與健康照護情境中的實用性與發展潛力。

1.2 研究目的

本專題旨在結合生成式語言模型與語音互動技術，設計並實作一套具備語音辨識、語意生成、情緒分析與虛擬角色表情同步功能的 AI 語音助理系統，提升語音互動的真實感與情感表達能力。現有語音助理多半侷限於語意理解與單向回應，缺乏情緒辨識與視覺互動能力，易造成使用體驗生硬。本研究導入串流式生成回應與 Live2D 表情驅動技術，使語音內容能即時與角色表情同步呈現，增強互動沉浸感。研究目的在於建構一套可實現語音指令操作、自然語言對話與情緒回應的語音助理原型，並驗證其在多任務控制與情感陪伴場景中的效能表現，期望為智慧居家互動與健康照護應用提供實用且具拓展性的系統架構。

1.3 技術發展與趨勢

近年來，情緒型 AI 助理以及使用者情緒分析的應用逐漸成為人工智慧領域的重要發展方向。多項研究與產業實例指出，結合語音辨識、自然語言處理與情緒分析技術的互動系統，能在各種情境中展現高潛力[1, 2]。

其可用的情境包括：

1. 客戶服務：

透過分析客服通話中顧客的語氣與情緒反應，系統可協助判斷顧客當下的情緒狀態，並依據分析結果提供建議，引導客服人員採取更合適的溝通方式，以提升顧客滿意度。

2. 醫療領域：

語音情緒識別技術可應用於輔助醫療與心理諮商，例如在憂鬱症、焦慮症、自閉症及阿茲海默症等疾病的診斷中，透過蒐集並分析患者語音中的情緒特徵與表達模式，進行相關數據紀錄與臨床評估。

3. 教育領域：

在教育應用方面，可運用語音情緒分析偵測學生的情緒狀態與學習投入程度，以判斷學生是否感到困惑、挫折或注意力不足，並依據結果調整教材內容或教學方式，以提升學習成效。

4. 娛樂領域：

在娛樂與遊戲產業中，情緒識別可用於打造更具互動性與真實感的個人化體驗，提升使用者的沉浸感與參與度。

根據相關報導，許多科技公司已投入情緒語音助理的開發，致力於讓系統能根據使用者語氣與情緒狀態，調整回應內容或語調，以提升人機互動的自然度與親和力。此趨勢顯示，未來的語音助理將不僅著重於指令執行效率，更關注互動過程中的情感理解與回饋[2]。

因此，本研究的設計方向與當前 AI 助理的發展脈絡相符，透過情緒辨識與視覺化呈現技術的結合，期望探索具情感回應能力的語音互動系統在真實應用情境中的可行性。



圖一 有關情緒分析功能的多種應用與市場估值

二、文獻探討

2.1 語音轉文字技術

在人工智慧語音助理的系統架構中，語音轉文字（Speech-to-Text, STT）模組扮演將使用者語音輸入轉換為文字資料，以供語言模型進行理解與生成的關鍵角色。隨著深度學習技術與雲端運算的進步，STT 的辨識準確率與延遲表現皆大幅提升，已能廣泛應用於日常對話、即時字幕以及無障礙溝通等多樣化情境。

早期研究多著重於語音訊號處理與隱馬可夫模型(Hidden Markov Model, HMM)結合聲學特徵的傳統方法。然而，隨著深度神經網路(DNN)及 Transformer 架構的出現，雲端 STT 服務逐漸展現更高的可擴充性與跨語言能力。例如，Microsoft Azure Speech 採用 DNN 與 Transformer 為核心，並整合雜訊抑制與回音消除模組，使其能在多雜訊環境中維持低延遲與高準確度[5]。同時，Azure Speech Studio 亦提供 Custom Speech 與 Phrase List 等客製化機制，使使用者可針對特定專業詞彙或口音進行調整，提升其在即時會議、智慧客服及家庭語音控制等場景的適用性[3, 5]。

不同平台間的比較研究顯示，OpenAI Whisper-large-v2 與 Azure Speech 在中文語境下的字錯率(Character Error Rate, CER)均能維持於 3% 以內，已能支援高準確度的無障礙轉譯需求[5]。相較之下，Google Cloud STT 雖支援逾 125 種語言，但在台灣口語語境下的 CER 約為 11%；而 AWS Transcribe 因中文支援不足，其 CER 甚至超過 200%[5]。這些差異顯示，STT 系統在跨語言或跨場域應用時，仍需透過語料最佳化與模型客製化以確保可靠性。

在實際應用方面，STT 技術已廣泛導入醫療、教育、金融與智慧城市等領域。例如，在醫療場域中，Azure Cognitive Services 結合自然語言處理(NLP)可協助醫師快速整理病歷與診斷資訊[4]；在教育領域，STT 技術則常用於即時字幕及語言學習平台，提升學習的可及性與互動性[4, 5]；針對無障礙溝通，更已有研究成功實現「中文語音 → 台灣手語」的跨模態轉換系統，驗證了 STT 與手語動畫結合的可行性[5]。

綜上所述，STT 技術已由傳統語音辨識逐步演進至深度學習驅動的多引擎架構，不僅展現高準確率與低延遲的特性，更具備跨領域應用的彈性。對本研究所開發之 AI 語音助理而言，Azure Cognitive Services Speech SDK 除了能提供穩定的中文即時辨識能力外，亦能與情緒分析及語音合成模組緊密整合，確保系統在智慧居家與健康照護等場景中兼具實用性與擴充性。

2.2 語音合成技術

在人工智慧語音助理的系統架構中，語音合成 (Text-to-Speech, TTS) 模組負責將語言模型生成的文字輸出轉換為自然流暢的語音訊號，以便提供使用者可聽覺感知的回饋。TTS 早期方法多基於拼接式 (concatenative synthesis)，透過大量錄製語音片段拼接而成，雖能維持一定自然度，但受限於靈活性與資料需求，難以支援多語音色或跨領域應用。隨後出現的統計式參數合成 (如 HMM-based TTS) 雖解決了靈活性問題，卻在音質與自然度方面存在明顯不足 [6]。此外，近年研究亦嘗試將 TTS 與多模態情感分析結合，使合成語音能隨對話情境調整語調與情感，提升人機互動的沉浸感與真實感 [7]。

在雲端服務方面，Microsoft Azure Speech 提供 Neural TTS，基於 Transformer 與多說話人建模技術，能生成接近人類自然語音的輸出 [8]。Google Cloud Text-to-Speech 與 Amazon Polly 亦提供多語言多音色的神經網路語音，但在中文表現上，Azure Neural TTS 的語調流暢度與情感表現更為自然。

在應用面上，TTS 技術已廣泛導入於無障礙服務 (例如閱讀輔助)、教育平台 (如語言學習與自動評測)、娛樂產業 (如動畫與遊戲角色配音) 以及智慧醫療 (如病患照護與陪伴機器人)。在大部份情境之中，能自然表達情緒的 TTS 系統皆有助於提升使用者的接受度與信任感。

綜上所述，TTS 技術已由早期的拼接式與參數式合成演進至深度學習驅動的端到端架構，兼具高自然度與可控性。對本研究所開發之 AI 語音助理而言，Azure Cognitive Services Neural TTS 不僅能提供穩定的中文語音合成能力，亦能支援情感化與多語音色輸出，確保系統在智慧居家與健康照護情境下的互動體驗更為自然與人性化。

2.3 大型語言模型

大型語言模型 (LLMs) 已成為智慧語音助理的核心技術之一。透過大規模語料預訓練與深層神經網路架構 (如 Transformer)，LLMs 具備上下文理解、語意生成與指令解析能力，能支援自然語言對話、多輪回應與人機互動。

首先，LLM 的發展歷程可分為四階段：統計語言模型、神經語言模型、預訓練模型與大型生成模型。近代模型 (如 GPT 系列) 結合 In-Context Learning 技術與超過千億參數的預訓練方式，大幅提升其在多語言、多任務與多模態情境下的效能 [9]。這些模型已廣泛應用於語音助理中的意圖理解、上下文回應與語意生成等關鍵任務。

在語音互動應用方面，已有研究設計結合 Whisper 語音辨識與 ChatGPT 文字生成的語音控制系統，部署於邊緣裝置 (如樹莓派) 以實現本地指令解析與設備控制。該系統採用 prompt engineering 提升模型理解力，並加入語意記憶模組，以強化上下文追蹤與多輪對話的一致性 [10]。此外，也有研究開發英語學習語音互動

系統，整合語音輸入、LLM 回應與語音合成模組，創造沉浸式練習場景，驗證其教育語音助理上的實用性[11]。

隨著多輪對話應用的發展，記憶機制逐漸成為語音助理的重要組件。相關研究提出語意摘要式短期記憶策略，將對話內容壓縮為摘要並重組為 prompt 輸入，達到降低 token 消耗、延長上下文保持的目的。使用者實驗顯示，語意摘要能顯著提升長對話中的一致性與反應品質[12]。此類摘要技術對於需持續與使用者互動的語音助理系統尤為關鍵。

此外，語音助理亦逐步結合情緒分析與回應調整機制，提升人機互動的溫度與情感連結。有研究利用 CNN 模型處理語音訊號，辨識使用者情緒，再結合 LLM 調整回應語氣與內容，使語音助理能根據情緒狀態進行個性化溝通[13]。這類設計對於居家陪伴型語音助理或照護情境下具有高度應用潛力。

在跨語言語音應用方面，部分系統也導入摘要式上下文強化策略，將先前對話摘要嵌入 prompt，以提升翻譯一致性與自然度。研究顯示，該方法能降低語意漂移現象，改善多語言對話助理在翻譯時的語境銜接品質[14]。

綜合而言，LLM 的應用已從單一任務回應延伸至整合語音辨識、語意生成、情緒分析與語意記憶的智慧語音助理架構。未來語音助理將不僅是輸入-輸出的轉換器，而是具備語境感知、個性化互動與情感理解能力的多模態對話夥伴，為智慧家庭與健康照護場域帶來更多創新可能。

2.4 情緒分析與互動式表情生成

在本研究系統中，情緒分析與表情生成模組構成了語音理解與視覺呈現之間的關鍵橋樑。此部分不僅負責辨識使用者語音或文字中的情緒傾向，也需將分析結果轉化為可視化的角色表情與語音語調，形成人性化的互動回饋。透過整合文字情緒分類與表情生成技術，系統得以在語意層面與感知層面同時回應使用者，使人機互動更具情感連結與自然流暢性。以下將分別說明使用者情緒分析方法與模型端情緒表情生成之設計與應用。

2.4.1 使用者情緒分析

在人工智慧語音助理的互動過程中，系統能否準確理解使用者的情緒狀態，對於回應的自然性與人性化程度有著決定性的影響。情緒分析的第一步通常來自於文字層面的情緒分類。有研究比較了多種情緒標註語料庫，指出資料來源、標註一致性與語境因素皆會影響分類模型的表現[15]。這說明在建構語音助理的情緒模組時，如何選擇與整合語料庫是一大挑戰。

針對情緒建模方法，現有的情緒模型分為三大類：類別型模型、維度型模型與延伸型模型。類別型模型如 Ekman 的六大基本情緒，具備簡單明確的標籤，便

於快速分類，但難以捕捉情緒強度。維度型模型則將情緒置於「效價—喚醒度」等連續空間中，能呈現情緒的漸變性。延伸型模型如 OCC 與人格五因子模型，進一步考慮個人特質與情境，強化了對複雜文本情緒的描述。這些不同取向的模型為語音助理提供了靈活的工具，可依需求選擇單純快速或細緻連續的判斷方式[16]。

另一方面，情緒不僅是靜態的分類結果，也與事件評價（appraisal）有關。探討了 Appraisal Theory，強調人類情緒是對事件意義的動態評估[17]，例如「是否符合目標」「是否可控」等認知判斷。將此理論應用於文本情緒分類，可以補足單純標籤分類的不足，並提供更符合心理學理論的解釋框架。這對語音助理而言，意味著系統不僅能判斷「快樂」或「憤怒」，還能理解背後的原因與語境，提升回應的合理性。

綜上所述，文字情緒分析的研究已經從資料蒐集、模型建構到理論支持逐步演進，為語音助理提供了從「識別使用者情緒」到「理解情緒成因」的完整基礎。

在 AI 語音助理的互動過程中，理解使用者的情緒狀態並據此調整語音回應的語氣，是提升人機互動自然度與親和力的重要關鍵。傳統語音助理多僅根據文字內容生成回應，缺乏對使用者情緒的感知能力，導致語音輸出在情感表達上顯得生硬、缺乏人性化。因此，整合情緒辨識（Emotion Recognition）與語音合成情緒調節（Emotion-aware TTS），成為智慧語音助理發展的重要方向。

首先，情緒辨識技術的核心目標在於透過多模態訊號來推斷使用者的情緒狀態，包括聲音語調、臉部表情與文字內容等特徵。情緒辨識可分為語音情緒偵測（Speech Emotion Detection）、臉部表情分析（Facial Expression Analysis）與文字情緒分析（Text Sentiment Analysis）三大類型。語音情緒偵測透過分析語音訊號的頻率、能量與音調變化，來判斷使用者是否處於喜悅、憤怒或悲傷等狀態；臉部表情分析則利用特徵點定位與深度學習模型來偵測表情特徵，例如嘴角上揚或眉頭緊皺；文字情緒分析則藉由自然語言處理技術，從語句結構與詞彙情緒傾向中推斷使用者情感。這些方法的整合能讓系統在語音互動中即時捕捉情緒變化，並作為語音生成時的情緒依據[18]。

而在多模態情緒辨識的應用上，有研究提出了一個結合影像與文字的多模態 AI 架構。該研究以 ViT-Tiny 模型進行臉部表情辨識，搭配 MiniLM 模型進行文字情緒分析，透過決策層融合（Decision-level Fusion）機制將兩種模態結果結合，選擇機率較高的情緒作為最終輸出。此架構能有效減少單一模態失準的情況，例如當使用者面部表情中性但語氣或文字顯示低落時，系統仍能準確捕捉情緒狀態。透過這種多模態融合機制，語音助理可在即時互動中動態判斷使用者的心理狀態，進而提升情緒識別的精確度與穩定性[19]。

此外，語音情緒辨識 (Speech Emotion Recognition, SER) 亦可輔助語音助理在聲音層面上掌握情緒特徵。該研究透過對語音信號進行預強化、分幀 (enframing) 與加窗 (windowing) 等前處理，再提取時域與頻域特徵，如梅爾頻率倒譜係數 (MFCCs)，以提升模型對細微語氣變化的敏感度。經由這些聲學特徵的分析，系統能分辨如悲傷語調的低頻能量下降、或快樂語氣中的高頻能量提升。此類特徵的即時分析結果可作為 TTS (Text-to-Speech) 語音合成時的情緒輸入，使語音助理能以更自然的語氣表達情感[20]。

2.4.2 模型情緒表情生成

情緒分析的結果若能進一步反映到虛擬角色的表情上，將大幅提升語音助理的互動性與沉浸感。傳統的語音驅動面部動畫多聚焦於口型與語音同步，但在情緒表達上表現不足。以深度學習方法建立了情緒可控的語音驅動 3D 面部動畫模型。其核心設計在於引入一個「情緒控制模組」，能將情緒類別與強度映射到面部參數，並在保有精準口型同步的同時，生成豐富的上半臉表情。此方法不僅突破了以往僅能產生中性表情的限制，還允許使用者自由調整情緒強弱，使動畫更貼近真實人類的情感波動[21]。

在 2D 動畫應用方面，官方提供的 Live2D Cubism SDK 教程[22]展示了如何透過 CubismAudioMouthInput 與 CubismMouthController 將 AudioSource 音量轉換為模型嘴巴的開合，實現口形同步。這種做法雖然僅依賴音量，無法表現複雜情緒，但提供了穩定且計算效率高的解決方案，適合作為基礎的視覺反饋機制。若能結合更進階的情緒分析結果，將口型同步與表情控制整合，就能讓虛擬角色不僅「會說話」，還能「帶情感地說話」。

總而言之，表情控制的研究已逐步從單純的語音口型同步，發展到情緒可控的多維表情生成。這使得語音助理的互動層次不再侷限於文字與聲音，而能進一步透過「臉部表情」傳遞情感，提升擬人化與沉浸感。

2.5 虛擬角色動態呈現與 Unity / Live2D 整合應用

在虛擬角色的呈現技術上，Live2D 提供了一套成熟的二次元角色動態表現框架。例如 2.4.2 節中提及的 Cubism SDK 能夠將原始的二維插圖轉化為可動態操控的模型，並支援與 Unity 等遊戲引擎的整合，使開發者能在即時互動應用中導入高品質的角色表現。

在即時互動的角色表情控制方面，Kühn 等人 (2020) 提出了基於語音情緒辨識的虛擬角色驅動方法。透過即時的語音情緒分析，他們能生成對應的臉部表情，提

升虛擬角色在社交互動中的自然度與沉浸感，對結合語音合成(TTS)與即時互動的應用具有重要啟發 [23]。

此外，虛擬角色的情感影響力亦與角色個人化設計密切相關。研究指出，當使用者能與角色建立更強的個人化連結時，角色在情緒表達與沉浸感上的效果會顯著提升，進而增強使用者的互動體驗與情感投入 [24]。

綜上所述，虛擬角色呈現技術已從傳統 3D 模型逐步發展至 2D 形變驅動的 Live2D 模式，並透過 Unity 的跨平台能力進一步拓展應用範疇。在語音助理架構下，Live2D 結合語音合成與情緒分析模組，能有效實現嘴型同步與情感表達，對提升智慧互動系統的沉浸感具有重要意義。

2.6 外部應用程式與網頁控制技術

在 AI 語音助理的應用場景中，單純的語音辨識與文字回應已不足以滿足使用者需求。現代使用者往往希望助理能夠直接操作外部應用程式或網頁，例如開啟瀏覽器、查詢天氣資訊，甚至進行跨平台的任務處理。這類能力需要語言模型不僅能產生語言輸出，還必須具備「工具使用」的能力，能夠正確決定何時以及如何呼叫外部 API。

大型語言模型若能結合外部工具，就能大幅擴展其應用範圍。例如，ToolLLM 提出了大規模的工具平台與基準，證明模型能夠透過合理規劃完成多步驟任務 [25]。雖然該研究聚焦於龐大的工具生態，但對於語音助理來說，其核心精神在於「如何讓模型在正確時機調用工具」。本專題即參考此概念，將瀏覽器開啟、天氣查詢等功能設計為小規模工具，讓語音助理能在對話中即時觸發。

另一方面，Toolformer 強調自我監督的學習方式，讓模型能在無需大量人工標註的情況下，自行學會 API 呼叫[26]。這種方法為語音助理的設計提供了啟發：當使用者需求超出文字生成範圍時，助理可主動判斷並選擇呼叫天氣 API 或啟動外部程式。透過這種「在需要時才使用工具」的策略，系統能避免冗餘呼叫並保持對話的自然性。

此外，GPT4Tools 進一步探討了如何透過自動生成的指令資料與輕量化微調，使開源模型也能正確使用外部工具[27]。雖然該研究涵蓋的多模態影像處理超出了本專題的範疇，但其方法論仍提供了啟發：語音助理若能以類似方式持續擴充工具集，將能在保持語音互動的基礎上，逐步拓展至更多應用場景。

綜合而言，相關研究共同指出了語言模型在「外部應用程式與網頁控制」上的發展趨勢：從 ToolLLM 的大規模工具規劃，到 Toolformer 的自我學習，再到 GPT4Tools 的擴展能力，皆顯示語音助理的未來不僅是語言回應，而是能夠主動協調外部資源，實現「語音輸入 → 工具調用 → 即時回饋」的完整互動流程。

2.7 語音情緒辨識

語音情緒辨識 (Speech Emotion Recognition, SER) 為智慧語音助理提升互動品質的關鍵模組，近年研究聚焦於如何藉由特徵工程與深度學習模型結合，以提昇系統對情緒的辨識準確度與即時性。

針對語音特徵輸入的前處理，常見方法為提取多種時頻域參數如 MFCC、Mel Spectrogram、Chroma、Tonnetz、Spectral Contrast 等，並進行順序堆疊組合以構建多通道輸入特徵。搭配 1D 卷積神經網路 (CNN) 設計 6 層架構，可有效捕捉語音中隱含的情緒特徵。進一步透過特徵順序優化與正規化操作，可提升情緒分類準確率至 90% 以上，顯示輸入特徵之組合與排列順序對模型辨識效果具有高度影響[28]。

為強化即時應用之可行性，系統設計上可採用基於 MFCC 與其一階導數構建的輕量模型，並將卷積層與全連接層進行融合。情緒辨識流程包含音訊切片、靜音移除、標準化處理、特徵提取至 CNN 分類器，整體流程具備低延遲與高準確率 (約 82.7%)，適合部署於具即時回應需求的語音助理系統中[29]。

另一方面，為解決語者語音變異性過大所造成的模型不穩定問題，可採用資料增強技術，例如訊號旋轉、裁切重組等，提升模型泛化能力。在架構方面，透過多層 1D CNN 搭配 Dropout 與 Batch Normalization 機制，可抑制過擬合並穩定訓練過程。於標準 RAVDESS 資料集上，整體辨識準確度可達 85% 以上，驗證該法在多語者情境下仍具高穩定性[30]。

針對多模態聲學特徵融合架構，可分別處理語音頻譜數值與其對應之二維聲譜圖，分別輸入 1D CNN 與 2D CNN 路徑後進行特徵合併，再以 MLP 進行情緒分類，能有效捕捉語音中局部與全域之時頻資訊。此種雙路徑融合架構於自建 EmoDSc 資料集測試下，辨識準確率達 97%，展示了融合式 CNN 設計於多特徵情緒辨識任務中的潛力與應用價值[31]。

此外，亦有研究採用深度前饋神經網路 (DNN) 搭配 MFCC、Delta 與 Chroma 等聲學特徵作為輸入，建構簡潔之分類模型，於 IEMOCAP 資料集上亦能達到 83% 準確率。該方法雖未使用複雜深度架構，仍展現出高效能，並具備低延遲與低資源消耗的優勢，適用於嵌入式或低功耗語音助理平台[32]。

綜合而言，SER 模型之準確性與可部署性取決於特徵選擇、前處理策略、CNN 設計與訓練技巧。未來發展可朝向 Transformer、自注意力機制、多模態融合與即時情緒轉換生成 (emotional TTS) 等方向，強化語音助理與使用者之情感互動與回應智慧。

三、研究內容與方法

3.1 系統整體架構設計

本專題所設計與實作之 AI 語音助理系統，旨在結合語音辨識 (Speech-to-Text + Speech-Emotion-Recognition)、大型語言模型 (Large Language Model) 回應生成、情緒分析 (Emotion Analysis)、語音合成 (Text-to-Speech)、虛擬角色互動 (Live2D 動畫控制) 以及外部功能呼叫 (External Function Calling)，構建一套具備即時互動、語意理解與多模態回饋能力的智慧語音平台。整體系統設計強調回應的自然性、互動性與情緒表達能力，並結合虛擬角色介面，提供擬人化與陪伴感兼具的語音互動體驗。


系統整體流程與模組架構如圖二所示，主要包含以下六大功能模組：

1. 語音輸入：系統透過麥克風擷取使用者的音訊訊號，並即時傳送至後端伺服器。伺服器中整合 Microsoft Azure Speech SDK，使用其雲端 STT (Speech-to-Text) 服務進行語音辨識，將語音內容即時轉換為文字。辨識結果將作為後續大型語言模型的輸入語句，進行語意理解與回應生成。為確保即時性，系統支援分段辨識機制，使文字可隨語音進度逐步呈現，避免等待語音輸入結束後才輸出文字，提升使用者互動的流暢度。另外，系統亦整合了語音情緒分析模組，以即時判斷使用者語音中的情緒狀態。此模組利用基於 Transformer 架構的語音分類模型進行特徵擷取，能從聲音訊號中分析語者的音高、節奏、能量與韻律變化，進而推測其情緒傾向（如高興、憤怒、悲傷或中性）。語音分析結果將作為系統理解使用者情緒的重要依據，以提升整體語意辨識的準確度與穩定性。
2. 大型語言模型：完成語音辨識後，轉換而得的文字輸入將透過 OpenAI 提供的 API 傳送至大型語言模型（如 GPT-4），由其進行語意分析與回應生成。本模組負責處理對話邏輯與語句表達，根據上下文與對話歷史產生自然、連貫且具人性化的回應內容。系統採用串流回應方式接收語言模型的輸出，意即模型會逐段 (chunk) 回傳文字片段，而非等待整句完成後才一次性傳回。此設計不僅可提升系統的回應速度，也方便後續模組（如情緒分析、語音合成與角色驅動）提早進行處理與同步操作。
3. 情緒分析：當語言模型生成文字回應後，系統會即時將該文字傳入情緒分析模組，進行語句情緒分類與特徵擷取。此模組可辨識回應內容所包含的主要情緒傾向（正面 (positive)、負面 (negative) 與中性 (neutral)）。情緒判斷結果將以標籤的形式提供給虛擬角色動畫模組與語音合成模組，作為其控制輸出的依據。此設計讓語音助理能根據語意呈現對應的情緒反應，不僅提升互動的真實感，也強化虛擬角色的表情自然度與語音語調的一致性。
4. 語音合成：語音合成模組負責將文字回應轉換為語音訊號，提供使用者聽覺回饋。系統採用 Microsoft Azure Neural TTS 作為語音合成引擎，該引擎結合 Transformer 架構與語者風格建模，能產生接近真人語音的自然輸出。根據情緒

分析結果，TTS 模組亦會自動調整語音的語速、音高與語調表達，使輸出語音更具情感溫度。系統支援即時語音生成，當回應文字尚未完全產出時，語音便可同步進行合成處理，有效縮短回應延遲，並與角色動畫實現同步驅動。

5. 虛擬角色互動：為提供更具臨場感的使用者體驗，本系統透過 Unity 結合 Live2D Cubism SDK 實作虛擬角色表情動畫控制。當系統完成回應生成與情緒判斷後，將依據語意內容與情緒分數，即時驅動虛擬角色的臉部表情、眼神動態與嘴型變化。角色動畫將同步配合語音播放節奏與語句段落，實現嘴型與語音的時間對齊 (lip sync) 效果。該模組可呈現多樣情緒狀態，如開心時微笑、悲傷時眉頭下垂，使使用者在互動過程中感受到角色的回應不僅真實，亦具備溫度與陪伴感。

6. 外部呼叫：系統同時設計了外部功能觸發機制，當使用者輸入的語句中包含特定控制指令（例如：「打開瀏覽器」、「查詢天氣」、「播放音樂」等）時，系統會透過關鍵字比對或語意判斷進行解析，並自動啟動對應的外部模組或顯示元件。以應用情境為例，系統可透過內部 API 觸發瀏覽器開啟指定頁面、執行搜尋操作，或進行行事曆相關的查詢與更新。此模組的設計使語音助理不僅能進行自然對話，亦具備任務導向的操作能力，從而在自由互動與功能控制之間取得平衡，大幅提升系統的實用性與可擴充性。



圖二 系統整體架構流程圖


3.2 語音分析

3.2.1 語音轉文字

本研究於語音助理系統中設計並實作一套語音轉文字 (Speech-to-Text, STT) 模組，作為整體架構的輸入來源與互動起點。該模組的核心目標在於將使用者的語音輸入即時、準確地轉換為文字，並提供給後續語意理解與回應生成模組進行語境

處理與語句生成，是整體語音互動流程中的第一道關鍵環節。STT 模組的效能與穩定性，將直接影響整體語音助理的使用體驗，因此在設計上需兼顧辨識準確率、反應速度、與語言適應性等多項技術指標。

在系統運作流程中，使用者透過麥克風進行語音輸入，前端將音訊資料即時擷取後傳送至後端 Python 伺服器。該伺服器整合 Microsoft Azure Cognitive Services 提供的 Speech SDK，呼叫雲端 STT 引擎進行語音辨識作業。STT 引擎內部包含語音訊號處理、聲學模型與語言模型等多個階段，透過深度學習方法進行語音特徵分析與推理，最終將輸入的語音轉換為文字輸出。由於辨識流程採用雲端架構，因此不僅可支援高精度辨識，也具備一定程度的可擴充性與穩定性。



圖三 使用 Azure 呼叫雲端文字轉語音功能之參考架構

在資料傳輸與處理方面，STT 模組將每一筆辨識結果即時回傳至主控伺服器，並自動存入系統的對話歷史紀錄。這些文字結果將作為後續語意理解與大型語言模型生成回應的依據，形成從「語音輸入 → 文字 → 語意 → 回應 → 表情/語音輸出」的完整語音互動流程。此外，考量使用者實際講話內容可能包含長句、停頓或語速變化，系統設計上亦支援分段式辨識 (partial result) 功能。當使用者尚未完整說完整段語音時，STT 模組即可先行回傳部分文字結果，讓系統能夠逐步處理語意，避免延遲至語音結束才開始處理。此特性有效提升整體互動的即時性與連貫性，並為多模組同步處理（如情緒分析、表情對應）提供先行資訊。

值得一提的是，由於語音助理的使用情境往往包含多語混用（如中英交錯）或口語化表達，本研究亦特別關注 STT 引擎的語言適應能力。Azure Speech SDK 支援中文（繁體）與英文語音辨識，並能自動辨識語句中常見的英文詞彙，如「AI」、「OpenAI」、「YouTube」等，有助於提升跨語種辨識的自然性與正確性。透過選用


成熟且具雲端資源支持的語音辨識服務，本系統得以在不額外訓練語音模型的情況下，實現穩定可靠的語音輸入處理流程。

綜合而言，語音轉文字模組作為語音助理的入口點，其性能與設計對整體系統架構至關重要。透過整合雲端 STT 引擎與分段辨識機制，不僅提升了語音處理的反應速度與準確性，也使系統能支援更具自然性與流暢度的語音互動體驗。未來若搭配語者辨識、自動語言切換等進階功能，STT 模組將更具彈性與智慧，進一步拓展語音助理於多元情境下的應用可能性。

3.2.2 語音情緒辨識

本研究在語音助理系統中實作語音情緒辨識 (Speech-Emotion-Recognition, SER) 模組，用以分析使用者語音中所表達的情緒特徵，輔助系統在互動過程中理解語者的情感狀態。與傳統僅依據文字內容進行情緒推論的方法不同，SER 模組直接從語音訊號中擷取情緒相關特徵，例如音高變化 (pitch)、語速 (tempo) 等，以偵測語音的情緒傾向。此模組能辨識的主要情緒包含高興(happy)、憤怒(angry)、悲傷(sad)與中性(neutral)，其輸出結果將作為系統情緒判斷的重要依據，進一步影響虛擬角色的表情呈現與語音語調調整。

在技術實作方面，SER 模組採用基於 Transformer 架構的 Wav2Vec 2.0 模型，並利用 Hugging Face 之 Transformers 函式庫中的 pipeline 進行實作。該模型以 IEMOCAP (Interactive Emotional Dyadic Motion Capture) 資料集為訓練基礎，該資料集包含多位語者在不同情緒下的自然與模擬對話語音，能有效捕捉情緒在聲學層面的差異。Wav2Vec 2.0 模型可將輸入的原始音訊波形轉換為高維語音特徵向量，並透過後端的情緒分類器進行分類推論，最終輸出各情緒類別的機率分布與標籤結果。



圖四 語音情緒辨識模組的簡易流程圖

綜合而言，語音情緒辨識模組的導入，使系統不僅能理解「語意上的情緒」，亦能感知「語音表達中的情緒」。透過語音與文字雙模態的情緒融合分析，虛擬角色能更真實地回應使用者的情感變化，並在語音語調與面部表情上展現一致的情緒

狀態。此模組的設計不僅提升語音助理的互動真實感，也為情緒化人機互動的研究與應用奠定基礎。


3.3 回應生成與對話歷史管理

回應生成模組是本 AI 語音助理的核心模組之一，其主要任務是透過大型語言模型（Large Language Model, LLM）進行語意理解與自然語句產生，進而與使用者建立具備情境感知與人性化的互動體驗。該模組不僅肩負語句生成的責任，更是整體語音互動流程中銜接語音辨識、情緒分析、語音合成與虛擬角色表情控制等多個模組的中樞環節。

在系統運作流程中，使用者首先透過語音輸入與助理互動，此語音資料會即時傳遞至語音辨識模組，轉換為對應的文字內容。辨識後的文字將成為回應生成模組的輸入，透過整合 OpenAI 的 GPT-4o 等高效能語言模型 API，搭配設計良好的提示詞（Prompt）格式一併送出，模型會根據語境脈絡、上下文歷史、語句語調與內建知識進行綜合分析，產生一段具邏輯性、語意連貫、且富人情味的文字回應。


與傳統一次性生成整段回應的方式不同，本系統採用串流回應模式（Streaming Response），即模型的回應內容將以多個片段（Chunk）的形式逐步傳回，實現低延遲的訊息傳遞。此設計可讓系統在模型尚未完成整段內容生成時，即可先行處理已接收到的部分，例如進行情緒偵測、語音合成與角色表情動畫驅動等任務。這種即時同步的特性大幅提升系統的反應速度與互動流暢度，尤其在視覺動畫與語音播放同步呈現時，能有效減少使用者等待感，進一步提升使用者體驗。

此外，為了實現語音助理的多功能性與指令可控性，系統亦內建簡易的指令解析機制。當使用者輸入語句中包含如「打開瀏覽器」、「關閉鬧鐘」、「開啟語音模式」等操作性語句時，模組會透過關鍵字比對或規則式語法分析進行辨識，進而觸發對應的應用模組。例如：「請幫我查詢現在的天氣」會觸發天氣查詢工具，「播放輕音樂」則啟動內部播放模組。此設計讓助理具備任務導向能力，兼顧自由對話與實用功能兩大面向，並具備良好的可擴充性，可因應未來新增指令模組的需求。



圖五 LLM 回應產生流程架構圖

為了解決大型語言模型在處理長對話時的 Token 限制問題，回應生成模組整合了對話歷史管理與摘要壓縮機制。系統會持續記錄每一輪對話內容，並以語意對齊為基礎進行分類與主題聚類，當對話歷史的 Token 數量逼近模型限制時，系統將自動啟動語意導向摘要流程。該流程會根據語意相似度與上下文關聯性，選擇性地合併重複語意、刪除冗餘資訊，並以簡潔摘要取代原始對話。此策略可有效延長對話持續時間，同時維持語境一致性，避免模型因 Token 過長而遺失重要語意脈絡。



圖六 LLM 處理 Token 限制問題流程圖

進一步地，本模組亦配合整體語音助理架構，將最終生成的文字回應同步傳送至語音合成模組與虛擬角色控制模組。語音合成部分會根據回應內容所分析出的情緒標籤（例如：positive、negative、neutral），自動調整語音的語速、音調與音量等參數，使語音表達更具情感與層次感。同時，Live2D 虛擬角色也會根據該情緒狀態自動呈現相對應的表情動畫，如微笑、皺眉、點頭等，打造出視覺與聽覺同步呈現的自然對話場景。這不僅提升了互動的沉浸感，也讓使用者感受到語音助理的溫度與擬人化特質。

綜合而言，回應生成模組不僅是語音助理的語言理解與生成核心，更透過串流輸出、指令解析、語意摘要與表情同步等多重機制，建構出一套即時、智慧、溫暖的人機互動系統。未來若搭配使用者記憶模組與多語系支援，可望進一步拓展應用情境，邁向更具陪伴感與實用性的 AI 語音助手願景。

3.4 語音合成

語音合成模組在本語音助理系統中負責將系統生成的文字回應轉換為自然、流暢且具有情緒表現的語音輸出，以提供使用者完整且富人性化的聽覺回饋。該模組為整體互動流程中的後端輸出環節，須確保語音輸出的品質不僅具備清晰易懂的語調，更能根據語句語意表現出適當的語氣與情緒，並與虛擬角色的動畫表情保持同步，實現語音與視覺的整合式回應。設計此模組時，系統需同時考量語音自然度、語調情感層次、語者風格變化與回應即時性等多項指標，以確保最終互動體驗具備高度沉浸感與互動真實性。

在實際系統流程中，語音合成模組緊接於大型語言模型（LLM）模組之後。當使用者語音輸入經由語音辨識與語意理解處理後，LLM 模組將產生文字回應，並立即傳送至 Python 伺服器中的 TTS 模組進行語音轉換處理。TTS 模組以 Microsoft Azure Cognitive Services 所提供的 Neural Text-to-Speech (Neural TTS) 技術為核心引擎，該引擎採用基於 Transformer 架構的語音合成模型，並結合多說話人建模能力，使合成語音具備高保真度、高靈活性與高度人聲擬真表現。

為進一步提升語音自然度與情緒豐富度，本模組亦充分運用 Azure Neural TTS 所支援的語音風格（Speech Style）與情感控制（Emotion Control）功能。系統可根據回應文字所分析出的情緒狀態，自動調整語音合成的參數設定，如語速（rate）、音高（pitch）、音量（volume）與音色（voice timbre）等，進而產生更貼合語境的語音輸出。例如，當系統判斷回應語句屬於正向、愉悅語意時，TTS 模組會調整為較為明亮、活潑的語音風格；而在面對悲傷或關懷類型語意時，則會改為柔和、低沉的語音輸出，以展現語助理的同理能力。此種基於情緒調控的語音合成，能強化語音助理的擬人特性與情感表達能力。

此外，語音合成模組亦支援即時語音合成功能（real-time streaming TTS），可在接收到部分文字內容時即開始生成語音資料，而非等待整段文字輸入完成後再進行批次轉換。此設計可顯著降低語音回應延遲，特別是在輸入句子較長或網路傳輸時存在延遲的情況下，更能有效維持對話流暢性與即時回應性。透過串流語音輸出，系統亦可同步觸發後續的動畫與表情控制模組，使整體輸出過程更加緊密協同。

為確保視覺與聽覺的同步輸出效果，語音合成模組生成之語音資料將與 Live2D 虛擬角色的動畫模組同步傳送與處理。系統會依據語音輸出的時間軸資訊與情緒分數控制角色的嘴型變化、眼神反應與面部表情，確保在角色「說話」的同時，對應的嘴型開合與語調一致，達成語音與動畫的時間對齊（lip sync）與語境匹配。此同步輸出設計不僅提升虛擬角色的擬人化程度，更能讓使用者在互動過程中獲得連貫一致的多模態回饋體驗。

整體而言，語音合成模組在本系統中扮演銜接語言理解與視覺回饋的關鍵角色。透過整合高品質語音引擎與情緒控制機制，並支援串流語音輸出與動畫同步能力，本模組有效提升語音助理的互動性與自然度。未來若能結合更多語音風格模型、聲線切換機制或自訂化語音訓練能力，語音合成模組將能進一步拓展其表達多樣性與互動情境適應能力，成為支援智慧語音體驗不可或缺的核心元件。

3.5 情緒分析與表情對應

在自然語音互動中，視覺回饋往往與語言表達同等重要。若虛擬角色在對話過程中始終維持單一表情，或表情變化與語意不符，將導致互動感受變得生硬、不協調，進而削弱整體的沉浸感與真實感。為解決此問題，本系統特別強化情緒分析與表情對應機制，使虛擬角色能根據使用者輸入與語音助理回應的語意內容，動態調整面部表情與語音語調，打造更為自然、擬真的語音互動體驗。


在整體系統設計流程中，使用者語音首先經由語音辨識模組轉換為文字，並傳送至大型語言模型模組以生成語句回應。此階段採用串流輸出的方式，逐段接收模型回傳的文字片段，並即時將其串接成完整語句。該語句隨後會傳遞至情緒分析模組進行語意判斷，模組採用基於詞彙特徵與語境資訊的情緒分類模型，對每一句回應進行情緒標註，並產生對應的情緒分數向量，涵蓋基本情緒類型，包括正面（positive）、負面（negative）與中性（neutral）等。

情緒分析的結果不僅作為語意理解的補充資訊，更直接驅動虛擬角色的視覺表情動畫。系統會將每一輪回應對應的情緒分數同步傳送至 Unity 端，並透過整合 Live2D Cubism SDK for Unity，將這些情緒數值轉換為動畫參數，以驅動角色的面部表情變化，例如嘴角弧度、張嘴幅度、眼神動態、眉毛位置等。角色的臉部表情主要依據 Live2D Studio 預先設計的表情參數模板進行控制，並透過設定表情強度與變化速度，使角色表現更符合語境所傳遞的情緒。例如，在正面情緒下呈現柔和

微笑與自然眨眼，而在負面情緒下則呈現眉毛調整、嘴角下壓等表現，實現語意與視覺表現的情緒一致性。

此外，此套情緒控制機制亦與語音合成模組密切結合。當語音合成模組接收到回應文字與情緒分數後，將依據該情緒特徵自動調整語音輸出的參數設定，例如：音高(pitch)。在正向情緒下，系統會提升音高，產生較為明亮、有精神的語調；而在負面情緒下則會降低音高，使語音呈現溫和且具同理感的表現。此聲音與表情同步驅動的設計，進一步強化角色的擬人化特徵，提升人機互動的情感深度。

語音輸入：



圖七 情緒與語音合成模組架構圖

總結而言，情緒分析與表情控制機制是本語音助理系統中實現自然互動的關鍵組件之一。其整合語意分析、情緒感知、視覺驅動與語音調控等功能，讓虛擬角色不僅說得像人，更能表現得像人，有效縮短人機之間的情感距離，提升互動的親和力與真實感。未來若能進一步融合語音語調分析、面部辨識與生理訊號等多模態情緒辨識技術，將能大幅提升角色反應的精準度與多樣性，邁向更具智慧、溫度與陪伴感的 AI 虛擬互動夥伴。

3.6 虛擬角色呈現與 Unity / Live2D 整合

虛擬角色模組的設計目標，在於將語音助理系統生成的語音回應與角色的表情、嘴型動畫進行即時且精準的同步，藉由「聲音—視覺」雙重回饋機制，提供使用者更具沉浸感與互動感的體驗。此模組扮演系統中關鍵的橋樑角色，不僅需要將

聽覺輸出有效轉換為視覺呈現，更必須兼顧即時性、自然度與穩定性，以確保整體互動過程具備真實感與連續性。

在系統流程上，語音合成模組（TTS）所輸出的音訊檔案（.wav 格式）會即時透過 Socket 通訊傳輸至 Unity 前端。Unity 端由 C# 撰寫的腳本負責接收音訊資料，並在播放語音的同時觸發對應的動畫控制。當音訊開始播放時，系統會依據語音波形能量（amplitude）與時間軸（timeline）資訊，驅動 Live2D 提供的嘴型動畫參數（Lip Sync），使角色的嘴部開合幅度與語音節奏保持一致。這種基於音訊能量與時間戳記的同步方式，可避免角色出現嘴型延遲或錯位，確保語音與嘴型動作的匹配度，提升使用者在互動中的真實感受。

除了嘴型控制外，本模組亦結合情緒分析模組的結果，將語音內容中辨識出的情緒類別（如正面（positive）、負面（negative）與中性（neutral））映射至 Live2D 的表情控制參數。這些參數能動態影響角色的眉毛、眼睛、臉部變化。透過這種「情緒—表情對應」設計，角色在不同情境下能展現更貼近語意的情感反應。例如，在正向情緒下，角色的表情會帶有笑意；而在負面情緒下，則呈現較為沉靜的眼神與表情，使角色在互動過程中更具擬人化特質。

在技術實作方面，本研究選用 Unity 作為前端整合平台，並搭配 Live2D Cubism SDK for Unity 進行角色動畫的細部控制。Unity 的可擴充性與即時渲染能力，使其成為承載虛擬角色模組的理想平台；而 Live2D Cubism SDK 則提供高精度的 2D 角色驅動能力，支援眼睛、嘴巴、表情等多維度參數控制。透過這種組合，本系統得以同時實現嘴型同步（Lip Sync）與表情動態（Facial Expression Control），達成聲音與視覺回饋的一致性。

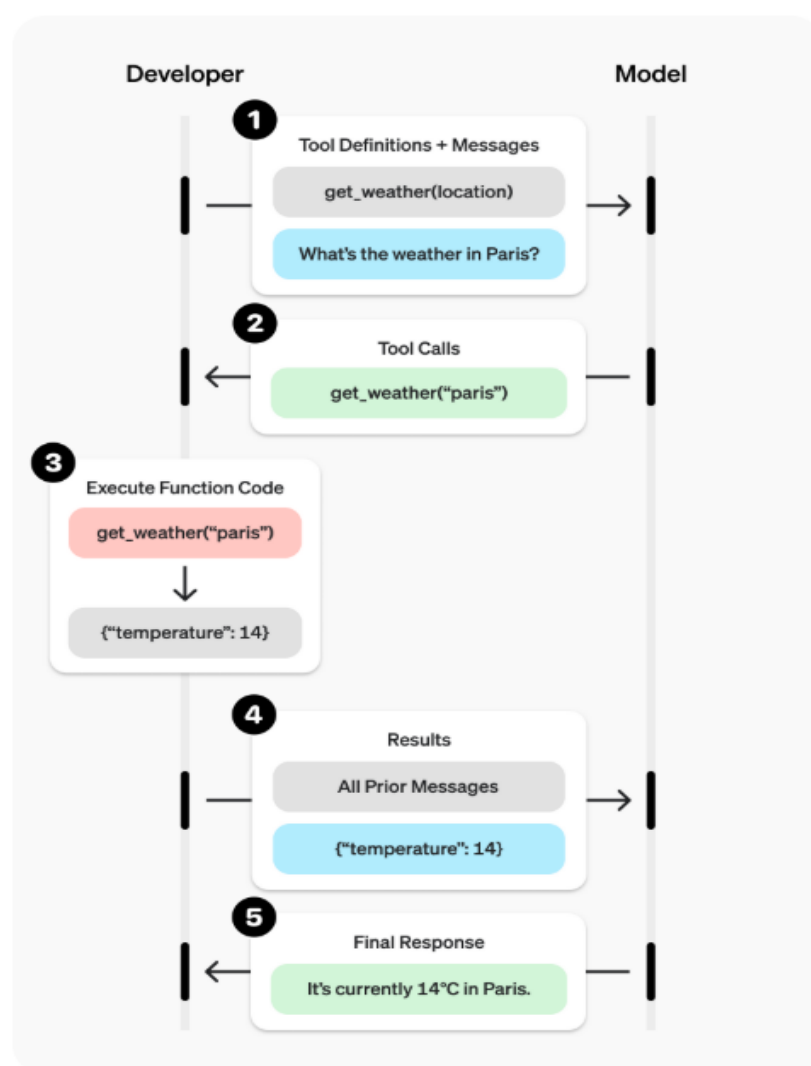
伺服器端與 Unity 之間的資料交換採用非同步通訊機制，以確保音訊在傳輸與播放過程中不會阻塞主線程，避免造成互動延遲或中斷。非同步設計的引入，使系統能同時處理音訊播放與動畫驅動，維持穩定的即時性輸出。同時，為了進一步提升同步精度，系統將語音合成過程產生的時間戳記與動畫驅動參數進行綁定，使嘴型動畫能夠精準對齊語音的每一個片段，減少「聲畫不同步」的問題。這種處理方式不僅提高了同步的穩定性，也讓角色表情與語音輸出達到高度融合的效果。

綜合而言，虛擬角色模組是本研究實現多模態互動的核心組件之一。它透過 Unity 與 Live2D 的結合，將語音回應與視覺表情有效同步，提供使用者兼具聽覺與視覺的沉浸式互動體驗。該模組在嘴型同步、情緒表情控制以及資料傳輸即時性等層面上均展現了良好的可行性與穩定性，為整體語音助理系統的擬人化與真實感提供了重要支撐。

3.7 外部應用程式呼叫與控制

在此語音助理系統中，除了核心的語音辨識（STT）、回應生成（LLM）、情緒分析與語音合成（TTS）模組外，亦需要具備與外部應用程式進行互動的能力，以滿足多樣化的應用需求。此部分的設計重點在於如何透過大型語言模型（OpenAI API）來分析使用者輸入的意圖，並決定是否需要觸發外部呼叫。

具體而言，如圖八所示，我們將系統中「文字分析與外部呼叫」的判斷工作交由 OpenAI 語言模型處理，也就是將「分析使用者意圖」的責任交由大型語言模型完成。透過此方式，系統不再需要額外設計複雜的規則式判斷，而是能直接利用語言模型的語意理解能力來識別使用者需求，並在必要時觸發外部工具的呼叫。這種設計不僅簡化了開發流程，也提升了整體的彈性與擴充性。



圖八 OpenAI 語言模型對工具函式呼叫的處理步驟

在此設計中，我們的角色作為開發者的聚焦點，主要在於提供語言模型一切必要的資訊，以便模型能正確判斷「何時需要呼叫哪一個程式」。而我們則負責確保當外部程式執行完畢後，相關結果能以標準化的方式重新整合回模型的對話上下文。此種設計讓語言模型在回應使用者問題時，能自然地融入外部資訊，避免出現斷裂或不一致的情境。

為了實現外部程式的呼叫，我們設計了兩種方法：

1. 瀏覽器啟動功能：當使用者指令涉及開啟網頁或進行線上查詢時，系統會透過 Python 的 `pypeteer` 套件來控制瀏覽器。此方式能直接開啟特定的網址，並作為一種最直觀的外部呼叫功能，讓語音助理具備瀏覽網頁的能力。
2. Unity 功能控制：除了瀏覽器外，其餘功能皆透過 Socket 通訊機制實現。Unity 在啟動時會作為 client 端，持續監聽指定的埠口；而 Python 主伺服器則作為 server 端，負責接收來自語言模型的外部呼叫請求，並轉換為對應的控制指令。當模型判斷需要觸發 Unity 功能時，伺服器會透過 socket 傳送相應的指令至 Unity 端。Unity 收到指令後，會交由內部的 C# 腳本進行解析，並根據指令內容觸發相應的功能模組，例如角色表情控制、動畫觸發或其他互動功能。此設計能確保前後端模組間的資料傳輸穩定且低延遲，同時保持系統擴充彈性。

綜合而言，外部應用程式呼叫與控制的設計使本系統能在自然語言理解與外部功能執行之間建立橋樑。語言模型負責決策「何時」與「如何」呼叫工具，而伺服器端則確保結果能正確回傳並整合入對話歷史，形成一個完整的閉環處理流程。此種設計方式有效增強了語音助理的多功能性，使其不僅能進行自由對話，也能靈活執行任務導向的控制操作。未來隨著外部工具的增加，系統亦能方便地透過相同框架進行擴充，支援更廣泛的人機互動應用場景。

3.8 串流架構整合與模組溝通流程

在本 AI 語音助理系統中，串流架構與模組間的即時溝通是核心設計理念之一，其主要目標在於實現低延遲、高流暢度的互動體驗，並確保多個模組之間能夠協同運作。整體設計採用 TCP socket 機制作為溝通橋樑，將語音辨識 (STT)、回應生成 (LLM)、情緒分析 (Emotion Analysis)、以及語音合成 (TTS) 等模組進行鬆耦合整合，透過逐步傳遞與串流輸出的方式，使整個對話流程具備高度即時性與彈性。

相較於傳統一次性回傳整段結果的方式，本研究採用的串流設計能讓各模組在結果尚未完全生成時便能啟動下一步驟，達到「邊生成、邊處理、邊輸出」的效果，這不僅降低了回應延遲，也讓系統能夠支援更自然的多輪互動。其運作方式可分為以下三個主要部分：


1. 請求接收與指令分派：主控伺服器透過 TCP socket 與 Unity 前端建立穩定連線，負責接收使用者的輸入資料與控制指令。當使用者透過麥克風輸入語音時，伺服器會先將其封裝後傳遞給 STT 模組進行即時轉換；若輸入為文字或特定操作指令，則可直接分派至 LLM 模組或其他相對應的功能模組。在這個過程中，伺服器的角色不僅是中繼站，更是任務分派器(dispatcher)。它需根據不同輸入類型(語音、文字、指令)快速判斷最合適的處理模組，並以標準化資料封包進行傳遞，確保各模組能在正確的時間啟動運作。此種設計使系統能同時支援一般聊天互動與功能性指令執行，兼顧靈活性與即時性。

2. 串流回應生成與逐步傳遞：當輸入文字送入 LLM 模組後，系統會透過 串流輸出機制(streaming response) 逐步獲取模型回應，而非等待整段完成。每當偵測到句號或語氣停頓等語意邊界，系統便能即時回傳部分結果。這些回傳片段不僅提供前端更快的回饋，還能立即觸發其他模組的協同處理：

- 情緒分析模組：在接收到片段文字後，立即對其進行情緒判斷，產生對應的情緒分數。
- 語音合成模組(TTS)：根據文字片段與情緒分數，開始生成語音資料，並透過 socket 傳回 Unity。
- Unity 前端：同時接收語音與情緒數據，控制角色嘴型與表情，使虛擬角色能即時展現聲音與情緒反應。

此串流處理方式讓回應生成、情緒驅動與語音輸出能同步並行，大幅縮短互動延遲，並維持對話的連貫性與自然感。

3. 外部資訊整合與歷史管理：除了核心的對話流程，主控伺服器亦能非同步呼叫外部 API，以獲取額外資訊支援。例如當使用者詢問天氣，系統可即時向中央氣象局 API 發送請求，並將回傳結果以 COMMAND 封包的格式回傳至 Unity 前端，使使用者能在對話中獲得即時的外部資訊。同時，系統內部設計有 對話歷史管理模組(Chat History Manager)，會將每一筆使用者輸入與 LLM 模組生成的回應存入 JSON 檔案。此舉一方面可提供上下文延續，使語音助理能記憶過往對話內容，避免語境中斷；另一方面，也能在長對話情境下透過摘要壓縮方式釋放資源，確保系統能維持長時間穩定運作。



圖九 串流架構與模組溝通簡易流程圖

綜合而言，串流架構整合與模組溝通流程的設計，透過 socket 即時通訊、串流回應機制、非同步 API 整合與歷史對話管理，成功實現了低延遲、高互動性的語音助理系統。這樣的設計使得各模組能夠鬆耦合又高度協同，並與 Unity 前端的角色與表情控制完美結合，帶來流暢自然的互動體驗。

憑藉其擴充性與彈性，該架構不僅能支援日常智慧對話，也能延伸應用於智慧家庭控制、健康照護服務與人機互動研究等多樣化場景，展現出本系統在真實應用上的廣泛潛力與價值。

四、實驗討論

4.1 實驗環境與開發平台

AI 語音助理的開發平台主要以 Python 3.10 為基礎，並搭配多項深度學習與語音處理相關套件，以支援 AI 語音助理系統的建置與測試。

在語音處理方面，系統使用 `azure-cognitiveservices-speech==1.44.0`，該套件提供高品質的語音辨識與語音合成功能，使得系統能即時將語音轉換為文字，並生成帶有情緒的語音回饋。此外，搭配 `azure-ai-textanalytics==5.3.0`，可進一步進行情緒分析與自然語言理解，提升對話互動的智慧性與準確性。

在回應生成方面，系統採用 `openai==1.93.3` 套件，負責與大型語言模型（LLM）串接，透過串流回應的方式逐步生成文字，並即時傳回至前端。此設計使得語音助理在回應過程中不需等待完整答案，能大幅降低延遲並提升互動流暢度。

在系統架構上，`aiohttp==3.10.11` 提供非同步網路請求能力，支援並行處理天氣查詢、外部 API 呼叫等任務，避免阻塞主流程。另使用 `pypeteer==2.0.0` 作為自動化模組，用於模擬瀏覽器行為，實現額外的網頁資訊抓取與外部資料整合。

綜合而言，本系統建構於模組化、可擴充的開發架構之上，整合雲端 API 與本地模組協同運作，不僅支援即時語音互動與多模組串接，也為後續功能擴充與應用場景測試提供穩定且靈活的基礎。

4.2 系統功能

本節主要針對所開發的 AI 語音助理進行系統功能測試，以驗證各模組在實際運作中的表現。由於本系統採用串流架構整合語音辨識、語意理解、回應生成、情緒分析、語音合成與表情同步等功能，因此需要逐項測試以確保整體互動流程的穩定性與即時性。

測試的重點包含四個方面：

1. 語音辨識與語意理解：檢驗系統能否正確將語音轉換為文字，並由語言模型理解語意並生成合理回應。

2. 回應生成與語音合成：評估 LLM 串流輸出與 TTS 語音合成的表現，觀察對話回應的即時性與自然度。
3. 指令控制與 Function Calling 機制：驗證系統的 Function calling 機制，以及對指令的處理能力。
4. 情緒判斷與控制功能：檢驗並觀察系統判斷情緒的正確程度。

透過這些測試能夠全面評估 AI 語音助理的實際運作狀況，並分析其在互動過程中的效能與使用體驗，作為後續系統優化的重要依據。

4.2.1 語音辨識與使用者情緒分析

在本系統的互動流程中，語音辨識與情緒理解為人機對話的前端關鍵階段。系統首先需能準確地將使用者語音轉換為文字，以利後續語意分析與回應生成；其次，為了使 AI 回應更具自然與人性化，亦嘗試辨識使用者語音中的情緒線索，藉此讓語言模型能根據語氣與情緒調整回應內容與語音語調。

4.2.1.1 語音內容辨識

在語音辨識與語意理解階段，系統使用 Microsoft Azure Speech-to-Text 進行即時語音轉文字。經測試，在普通語速與清晰發音條件下，其整體辨識效果相當穩定，能準確辨識一般中文語句，適合即時互動應用。

辨識結果會即時傳送至語言模型進行語意理解與回應生成，LLM 對於口語化輸入的處理大多表現良好，整體流程運作順暢。為避免多輪對話中出現語意不連貫的情形，系統整合了對話歷史管理與摘要機制，使模型能根據先前內容維持語境一致性，進而提升互動自然度與連貫性。

4.2.1.2 語音情緒分析模組選擇

在語音情緒辨識階段，系統原規劃整合第三方情緒分析 API，以提升互動回應的自然性與情感表現。為此，曾針對多個可用的語音情緒分析模組進行測試，其中包含 Imentiv AI、SpeechBrain 與 Hugging Face 的 transformers 模組。各服務的測試結果如下：

- Imentiv AI

Immentiv AI 提供完整的語音上傳與情緒分析介面，可同時輸出文字轉錄與情緒報告。測試中上傳音訊資料，但伺服器回傳 403 (Domain not recognized) 錯誤。

研判原因為該服務僅允許從官方網域或授權來源發出請求，無法在本地或雲端測試環境中使用。由於無法獲取授權憑證，最終未納入系統。

• SpeechBrain

SpeechBrain 為開源的語音處理工具包，支援語者辨識與情緒辨識等多項功能。實測時透過官方提供的情緒分類模型進行推論，可辨識多種基本情緒。

然而，在實際環境中，因 PyTorch 版本問題以及使用 Symlink 檔案權限問題導致模型無法順利載入與運行，需重新配置特定版本的依賴環境方能使用。考量整體系統維護成本與開發時間，因此最終也未將 SpeechBrain 納入正式系統。


• Transformers

Transformers 是 Hugging Face 的開源自然語言與語音模型庫。它提供了一個「pipeline」介面，可以讓使用者快速執行特定任務，例如文字分類、圖像分類、以及音訊分類（包含情緒分析）。

Pipeline 雖然無法判斷太過細膩的情感，但在使用上較為簡易且輕量化，符合我們的專題需求，因此最後選則此套件作為我們的語音情緒辨識模組。

4.2.1.3 情緒分析正確率測試

此部分針對 Transformers 的語音情緒分類模型進行正確率評估，所使用的測試資料為公開語音情緒資料集 RAVDESS[33]。此資料集包含多位語者以不同情緒朗讀句子的錄音，情緒類別涵蓋喜悅 (happy)、憤怒 (angry)、中性 (neutral) 與悲傷 (sad) 等。本實驗將各情緒的音訊分別輸入模型進行分類，並整理預測結果以形成混淆矩陣，以呈現模型在不同情緒類別下的辨識表現。



圖十 語音情緒分類模型的正确率測試，並以混淆矩陣表示結果

混淆矩陣顯示，模型在辨識憤怒時相對穩定，但在處理其他情緒時，預測結果不夠理想，錯誤分類的情形較為明顯。此結果反映該語音情緒模型在本測試資料上的辨識能力有限，也可能受到資料來源、語者表達方式以及模型訓練資料分佈差異的影響。

4.2.2 回應生成與語音合成

在回應生成階段，系統採用 OpenAI 的大型語言模型（LLM）作為主要核心，並同樣透過 API 進行即時文字生成。實驗過程中，模型能根據使用者語句與對話歷史生成自然、連貫的回應內容。由於採用了串流式回傳機制，系統能在語句生成尚未完成時，即時將部分文字輸出至後續模組進行語音合成與虛擬角色表情控制，達到視覺與聽覺同步的效果。

在實際測試中，LLM 模型在一般對話與任務指令之間能靈活切換，並能透過 Function Calling 呼叫外部應用程式執行特定操作。此功能於 4.2.3 節說明。

接著，關於 TTS 模型選擇方面，在語音合成的實作過程中曾嘗試使用多種不同的語音生成技術。初期採用開源 AI 模型(如 Coqui TTS)，但其在生成速度與硬體資源需求上負擔較高，對一般開發環境的即時運作造成限制。後續嘗試以 Google 提供的語音合成服務進行測試，但在中文語音表達上自然度不足，情緒語調變化亦不明顯。

因此我們最終選擇在此專案中使用 Microsoft Azure Speech Service 作為主要的 TTS 解決方案，其在跨語言表現與整合便利性方面較為穩定。然而，Azure TTS 雖然可以自定義其語調和語速等不同語音參數，但其中的繁體中文語音的語音資料庫不如其他語言如英語語音資料庫全面，其並無直接支援情緒模組，部分語氣表達仍較為生硬。整體而言，Azure TTS 提供穩定且可擴充的語音生成能力，但在語音情感細緻度與中文情緒語音支援方面仍有改進空間。

在語音合成與 Unity 系統的整合階段，主要採用伺服器端生成語音檔後以 socket 傳輸至 Unity 進行播放的方式。其遇到的問題主要集中於資料傳輸與物件設定層面。由於系統透過 socket 傳遞的資料除音訊資料之外同時也需傳入控制指令，初期測試時曾出現格式不符(如音訊頻率不符)、資料解析錯誤(如誤將傳入的文字指令當成音訊資料播放)等問題。經過調整傳輸協定與檔案處理流程後，系統已能穩定接收、正確判斷指令並播放從伺服器傳送的語音資料。

4.2.3 指令控制與 Function Calling 機制

在指令控制功能的設計初期，系統採用了以關鍵字比對為主的方式進行指令判斷。此方法雖能快速辨識特定語句(如「播放音樂」、「現在時間」等)，但對語句表達方式的彈性嚴重不足，使用者若以不同說法輸入相同意圖，系統可能無法觸發操作或是誤觸發錯誤操作等。為改善此問題，後期改以語言模型(LLM)進行語意分析，由模型判斷使用者意圖後，再透過 Function Calling 機制呼叫外部程式執行。

在與 Unity 整合方面，系統以 socket 通訊方式向 Unity 傳遞執行指令，Unity 端作為 client 接收並觸發對應操作，例如傳入天氣資訊或觸發動畫事件。經測試後，指令傳遞延遲穩定於可接受範圍內，驗證了語言模型驅動的指令控制在多模態互動中的可行性與穩定性。

Function Calling 是一種讓大型語言模型能主動觸發外部函式呼叫的技術，使模型在回應過程中不僅能生成文字內容，亦能執行程式層面的動作。

其基本運作流程如下：當模型接收到使用者輸入後，會根據語意判斷是否需要執行外部功能。若判斷需要執行，模型便會以 JSON 格式輸出對應函式名稱及其參數，由主伺服器解析後呼叫實際的外部程式。執行結果再回傳給模型，使模型能在回覆中反映操作結果或狀態變化。此設計讓系統能在單一對話流程中同時處理自然語言生成與程式邏輯操作，達成語言驅動的多模態互動。

在本專題中，Function Calling 主要應用於 UI 控制指令。例如當使用者提出「幫我將行程加入行事曆」或等語句時，語言模型能自動轉換成對應的函式呼

叫，並透過 Socket 傳遞至 Unity 程式端。Unity 端在接收到指令後，會根據參數執行介面操作 UI 元件。

```
{ # 時鐘元件控制
  "type": "function",
  "name": "clock_UI_trigger",
  "strict": True,
  "description": "Have the clock gadget pop up.",
  "parameters": {
    "type": "object",
    "properties": {},
    "required": [],
    "additionalProperties": False
  }
},
```

圖十一 Function Calling 請求 JSON 之範例格式
(此處為控制時鐘元件)

Function Calling 在本系統中扮演了語言理解與外部動作間的橋樑，大幅提升語音助理的可擴充性與互動性。未來若需新增其他功能（如開啟應用、播放音樂或控制外部裝置），僅需在伺服器端定義新的函式介面，便能透過相同的架構實現語言驅動的操作流程。

在實驗過程中，我們主要驗證了語言模型透過 Function Calling 機制，能否正確辨識語意並觸發對應的 Unity 端功能。結果顯示，在多數指令下，語言模型能正確解析多數指令語句，並自動忽略無關內容，提升了整體準確率與自然互動性。整體而言，語意導向的指令判斷在靈活度與可擴充性上表現明顯優於關鍵字匹配，因此能有效串接 LLM 與 Unity，具備良好的可擴充性與應用潛力。

另外，原始設計構想中，系統預期可透過語音指令控制智慧家電等外部裝置，以驗證語言模型在實體環境互動中的應用潛力。然而，因開發環境未連接實際硬體裝置，最終以模擬的 UI 控制（如行事曆開啟、提醒事件新增等功能）作為替代實作。此做法使系統仍能驗證指令解析與外部應用控制的整合流程，並保留日後擴充至智慧家庭場景的可能性。

4.2.4 情緒判斷與控制功能

本節著重於系統在情緒層面的辨識與反應機制，說明如何透過語音與文字資訊進行情緒分析，並將結果應用於虛擬角色的動態呈現。情緒控制模組的設計不僅影響語音語調與表情動畫的自然度，也左右了整體互動體驗的情感真實性。

以下各小節將依序說明情感分析的連貫性處理、時間序列平滑化方法、情感分析模組的選擇與評估，以及使用者層面的情緒互動觀察。

4.2.4.1 情感分析的連貫性

情緒辨識功能是系統與使用者進行互動的關鍵。在功能設計初期，我們使用二元情緒分類 (Binary Sentiment Classification) 的模型，將語音助理輸出的整段文字（而非單句）劃分為三大類情感極性：正面 (positive)、負面 (negative) 與中性 (neutral)。

這種粗粒度 (Coarse-grained) 的分析方式雖然能提供整體情緒傾向，但上下文理解不足。特別是當語音輸出內容較長或包含多個複雜句時，單一情緒標籤無法準確呈現對話中的變化以及走向。

為提高即時性和準確性，我們嘗試將文本劃分為單一句子 (Sentence-level) 進行獨立分析。然而，此細粒度 (Fine-grained) 分析策略卻導致情緒波動過大且不自然的新問題。例如，使用者可能在極短時間內因兩句不同的陳述，使系統的情緒評分從極正驟變成極負，嚴重影響人機互動的流暢性與可信度。

4.2.4.2 情緒平滑化與時間序列控制

為了模擬人類情緒變化的漸進性與連貫性，我們引入了時間平滑函數 (Time-based Smoothing Function) 來處理情緒分數過快的變動。

該函數的原理是將當前的單句情緒得分 $E_{mcurrent}$ (當前的情緒) 與前一句話的加權情緒平均值 $E_{mprevious}$ (前一句話的情緒) 進行運算，得出新的平滑化情緒分數 $E_{mosmooth}$ 。我們使用一個衰減因子 (Decay Factor) α ，透過一階指數移動平均 (First-Order Exponential Moving Average, EMA) 的數學模型實現情緒的穩定：

$$E_{mosmooth} = \alpha \times E_{mcurrent} + (1 - \alpha) \times E_{mprevious}$$

- ($\alpha = 0.6$) e

透過此機制，情緒的轉變不再是說一句話變一個人，而是呈現時間上的漸進過渡，有效解決了情緒變化過快過大的問題，使語音助理的回應更貼近自然對話。

4.2.4.3 情感分析模組的選用與評估

在選擇情感分析模組時，我們評估了開源(使用 Snownlp)與雲端 API(使用 Text Analytics with Azure AI)的選項。

開源模組 (Snownlp)的優勢在於採用了 Snownlp 這一支援中文文本分析的開源函式庫，其本地運行的特性確保了數據的隱私和比較快的運算速度，且完全不依賴外部網路，但是經實際測試發現，由於 Snownlp 的底層語料庫主要使用簡體中文 (Simplified Chinese) 構建，在處理臺灣慣用詞彙、繁體中文的網路流行用語或特定俚語時，其表現極差。大多數情感豐富的表達會被錯誤地歸類為「中性」(neutral)。

雲端服務 (Text Analytics with Azure AI)鑑於開源模組在繁體中文在地化上的嚴重缺陷，我們最終決定採用 Text Analytics with Azure AI 的雲端 API 進行情緒分類，Azure AI 具備多語言翻譯和多語系情感分析能力，尤其對於繁體中文的辨識準確性遠高於 Snownlp，顯著提高了系統的情緒判斷品質。然而，此方案的缺點是非本地非開源，運行速度相對較慢，且會產生 API 呼叫成本。但考慮到判斷的準確性是有相當顯著的提高，我們認為犧牲部分運行速度以換取更高的專業度是必要的權衡。

4.2.4.4 情感分析與使用者

情感分析除了作為表情控制與語音語調調整的依據外，更關鍵的是，它能進一步影響語言模型 (LLM) 的回應風格與互動策略，進而強化語音助理與使用者之間的情感連結。

使用者輸入的語句 (語音轉文字後) 會先經過情緒分析模組判斷其情緒傾向 (正向、中性、負向)。該結果將作為提示詞 (prompt) 的附加上下文，回饋至 LLM 進行回應生成。具體而言，系統會在每次與 LLM 的溝通請求中，於提示詞中加入使用者當前的情緒狀態，使 LLM 除了依據對話歷史與使用者輸入以外，還能根據其情緒傾向產生更貼近心理狀態的語句。藉此實現更具同理性與互動溫度的語音助理回應風格。

這種方式讓語言模型不再只是「回應輸入的文字內容」，而是能根據使用者的情緒狀態調整語氣與措辭，從而展現更具人性化的互動能力。例如，當使用者表現出焦慮、沮喪或負向語氣時，語音助理將以關懷與鼓勵語句回應，如「我了解你的感受，想跟我聊聊嗎？」而非一般性的事務性回覆。

此外，系統也能根據情緒分數變化趨勢，判斷使用者是否處於情緒波動期，進一步選擇較溫和、低刺激性的回應策略，以避免激化負面情緒。這樣的

互動調節機制，不僅提升了語音助理的應對彈性，也使整體對話更具溫度與同理性。

整體而言，將情緒分析結果融入 LLM 回應生成流程，是提升語音助理擬人化表現的關鍵之一，使其從語言工具轉化為具備情感理解能力的互動代理角色。

4.2.5 模型選擇

在模型選擇時我們需要考慮幾個方面：邏輯、執行速度、說話方式。

各方面都有需要的考量，邏輯方面需要模型能夠透過側面或暗示都方式來執行指令，與傳統的關鍵詞偵測能夠做出區別，而在速度方面需要快才能讓回應更像是真人回答，目前模型的速度都接近真人的反應速度，但是我們需要經過執行函式、確認函式是否成功、回應的三輪步驟，所以速度方面需要選擇較快的模型，說話方式則需要更加具有同理心或是情感，讓使用者的體驗更好。

在對比這三個方面時，我們測試了 Gemini 2.5 Flash、Gemini 2.5 Pro、Chatgpt 4o、Chatgpt 4o mini，Gemini 2.5 Flash 在邏輯方面的能力很差，無法透過主動詢問或是推理的方式來得知使用函式，明確指定函式時也不一定會執行，而速度是測試模型中最快的，說話方式是 gemini 的風格不會有過多的感情，Gemini 2.5 Pro 在邏輯方面的能力是不錯的，能夠推理使用者的需求並選擇函式，速度方面則是之中最慢的，需要超過十秒才能夠回應，遠超過正常對話該有的反應時間，說話方式一樣是 gemini 的風格，而 Chatgpt 4o 的邏輯方面也是不錯的，能夠推理使用者的需求並選擇函式，速度方面大約在 5-8 秒能夠回答，說話方式是 chatgpt 固有的過多正面以及鼓勵不太像是正常該有的情緒，Chatgpt 4o mini 的邏輯方面會比 gemini 2.5 Flash 好一點，推理使用者的言外之意和需求較困難，但只要明說就能夠成功執行，但速度方面只比 4o 快一秒左右，說話方式一樣是 chatgpt 的方式，過多正面以及鼓勵不太像是正常該有的情緒。

五、結論

5.1 結論

本專題以語音辨識、情緒分析及虛擬角色呈現為核心，建構出一套具即時互動能力的 AI 語音助理系統。整體架構展示了多模態人工智慧技術的整合可行性，並在語音處理、內容生成與視覺呈現間建立了穩定的資料流。系統具備良好的即時性與可擴充性，可應用於智慧居家、教育輔助及情感陪伴等情境，展現 AI 語音助理在自然人機互動領域的實用潛力。

5.2 未來展望

本專題已成功整合語音合成、語言模型與虛擬角色呈現，驗證了多模態互動的可行性，但仍有進一步提升的空間。未來可從語音品質、互動自然度與模型反應效率等面向進行優化。

在技術層面，語音合成可朝更細節的情緒化與個人化聲線方向發展，以提升語音表達的自然度。語言模型則可透過強化記憶機制與降低延遲時間，改善多輪對話的即時互動體驗。虛擬角色的呈現亦可結合更動態的控制方式，使表情與語音情緒更加自然。另外此系統的語音情緒辨識功能也仍有改善空間與可發展的功能，如透過分析使用者語音特徵與上下文語意內容推估其情緒狀態，並自動調整回應語氣與角色表情，以提供更具情感回饋的人機互動體驗等。

參 考 文 獻

- [1] 楊政霖(2018)。產業技術評析 情緒辨識應用案例分析。經濟部技術處。檢自 https://www.moea.gov.tw/MNS/doit/industrytech/IndustryTech.aspx?menu_id=13545&it_id=184
- [2] Meredith Somers(2019). Emotion AI, explained. MIT Sloan School of Management. Retrieved from <https://mitsloan.mit.edu/ideas-made-to-matter/emotion-ai-explained>
- [3] Edqvist, J., & Lennartsson, R. (2019). Chat Bots & Voice Control: Applications and limitations of combining Microsoft' s Azure Bot Service and Cognitive Services' Speech API. Bachelor Thesis, Faculty of Health, Science and Technology, Computer Science, Karlstad University.
- [4] Oye, E., Frank, E., & Owen, J. (2024, December 22). Real-World Applications of Azure Cognitive Services in .NET Development.
- [5] 劉, 蘋慧 (2025). AI 深度學習之中文語音無障礙轉譯：從語音轉文字到手語呈現 (碩士論文). 國立中華大學電子工程系碩士班.
- [6] Zen, H., Tokuda, K., & Black, A. W. (2009). Statistical parametric speech synthesis. *Speech Communication*, 51(11), 1039 – 1064.
- [7] R. Skerry-Ryan, et al., “Towards end-to-end prosody transfer for expressive speech synthesis with Tacotron,” in *Proc. ICML*, 2018, pp. 4693 – 4702.
- [8] Microsoft Azure Cognitive Services. Neural Text-to-Speech (TTS) Documentation. Microsoft Docs.
- [9] Zhao et al., "A Survey of Large Language Models", arXiv:2303.18223, 2023.
- [10] 張志豪,《結合語音輸入與大型語言模型指令翻譯之樹莓派智慧家庭控制系統》, 國立東華大學碩士論文, 2024。
- [11] 杜宜霖,《以 GPT 語言模型為核心之 LINE 英語學習助理系統設計》, 2024。

- [12] Mikael Törnwall, "Contextual Short-Term Memory for LLM-Based Chatbot", KTH Royal Institute of Technology, 2023.
- [13] Popescu et al., "Voice Based Emotion Recognition with CNNs for Companion Robots", 2022.
- [14] Jang et al., "Context-Aware LLM Translation System Using Conversation Summarization", 2024.
- [15] Bostan, L. A. M., & Klinger, R. (2018). An analysis of annotated corpora for emotion classification in text. In Proceedings of the 27th International Conference on Computational Linguistics (pp. 2104 – 2119). Association for Computational Linguistics.
- [16] Bruna, O., Avetisyan, H., & Holub, J. (2016). Emotion models for textual emotion classification. Journal of Physics: Conference Series, 772(1), 012063. IOP Publishing.
- [17] Clavel, C., & Callejas, Z. (2016). Appraisal theories for emotion classification in text. IEEE Transactions on Affective Computing, 7(4), 399 – 411.
- [18] Zhu, C. (2023). *Research on emotion recognition-based smart assistant system: Emotional intelligence and personalized services. Journal of System and Management Sciences*, 13(5), 227 – 242.
- [19] Rajesh, S. G., Niveditha, V., & George, D. (2025). *Enhancement of virtual assistants through multimodal AI for emotion recognition. IEEE Access*, 13, 3577664.
- [20] Kawahara, T., et al. (2025). *STUDIES: Corpus of Japanese empathetic dialogue speech towards friendly voice agent. Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 1 – 5.

- [21] Chen, Y., Zhao, J., & Zhang, W.-Q. (2024). Expressive speech-driven facial animation with controllable emotions. arXiv preprint arXiv:2301.02008.
- [22] Live2D Inc. (2020, January 30). Cubism SDK for Unity: 口形同步设置教程 [Lip-sync tutorial]. Live2D Manuals & Tutorials.
- [23] Kühn, S., et al. (2020). Emotion-driven avatars: Real-time facial animation based on speech emotion recognition. *Proceedings of IVA 2020*.
- [24] The Influence of Avatar Personalization on Emotions in VR.
- [25] Tang, B., & Shin, K. G. (2024). Steward: Natural language web automation. arXiv preprint arXiv:2409.15441.
- [26] Schick, T., Dwivedi-Yu, J., Dessi, R., Raileanu, R., Lomeli, M., Derczynski, L., ... & Kiela, D. (2023). Toolformer: Language models can teach themselves to use tools. arXiv preprint arXiv:2302.04761.
- [27] Yang, R., Song, L., Li, Y., Zhao, S., Ge, Y., Li, X., & Shan, Y. (2023). GPT4Tools: Teaching large language model to use tools via self-instruction. arXiv preprint arXiv:2305.11554.
- [28] Fadhil, M. F., & Zahra, A. (2023). Speech emotion recognition with optimized multi-feature stack using deep convolutional neural networks. BINUS Graduate Program, Master of Computer Science, Bina Nusantara University.
- [29] Rahman, M. M., Ahmed, M. K., Hossain, M. A., Sultana, R., Hasan, T., & Islam, M. S. (2023). EmotionNet: Pioneering deep learning fusion for real-time speech emotion recognition with convolutional neural networks. Department of Computer Science and Engineering, Prime University, Bangladesh.
- [30] Verma, R., Chauhan, A., Naithani, S., Rawat, S., Rawat, A., & Singh, P. (2024). An advanced framework for emotion recognition from speech using deep convolution approach. 2024 3rd International Conference for Innovation in

Technology (INOCON).

[31] Begazo, R., Dongo, I., Aguilera, A., & Cardinale, Y. (2024). A combined CNN architecture for speech emotion recognition. *Sensors*, 24(x), xx – xx.

Universidad Católica San Pablo & Universidad de Valparaíso & Universidad Internacional de Valencia.

[32] Desai, P., Chakraborty, S., Sujatha, C., Desai, P., & Ansuman, S. (2024). Speech emotions detection and classification based on speech features using deep neural network. School of Computer Science & Engineering, KLE Technological University, India.

[33] Livingstone SR, Russo FA (2018) The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English.